Centro Universitário Álvares Penteado – FECAP

Ciência da Computação

Análise Inferencial de Dados

Prof. Rodnil Lisboa

ENTREGA 01

Esther Oliveira Costa – RA 24026817

Higor Luiz Fonseca Dos Santos – RA 24026818

João Victor De Faria Santana – RA 24026811

SÃO PAULO

2026

1. STOREORDER

1.1 Medidas de posição e dispersão

Esta seção apresenta as principais medidas estatísticas das variáveis numéricas do dataset STOREORDER. Optamos por utilizar apenas esse dataset, pois é o que possui os melhores dados numéricos para está parte entrega. Foram calculadas média, mediana, moda, variância e desvio padrão para cada variável numérica, com exceção do campo status, pois os números correspondem a status qualitativos.

Variável	Média	Mediana	Moda	Variância	Desvio Padrão
totalamount	57.3276	45.91	31.48	3131.6024	55.9607
subtotalamount	55.9855	44.9	25.0	3071.6296	55.4223
discountamount	5.4165	3.15	0.0	44.368	6.6609
taxamount	6.7915	6.98	0.99	20.4725	4.5247

1.2 Visualizações gráficas

Foram geradas visualizações para analisar a distribuição dos valores de pedidos. Os gráficos incluem versões com escala completa e versões focadas na distribuição principal dos dados (até o percentil 99), permitindo observar tanto os outliers quanto o comportamento predominante das transações.

1.2.1 Histograma - Escala Completa

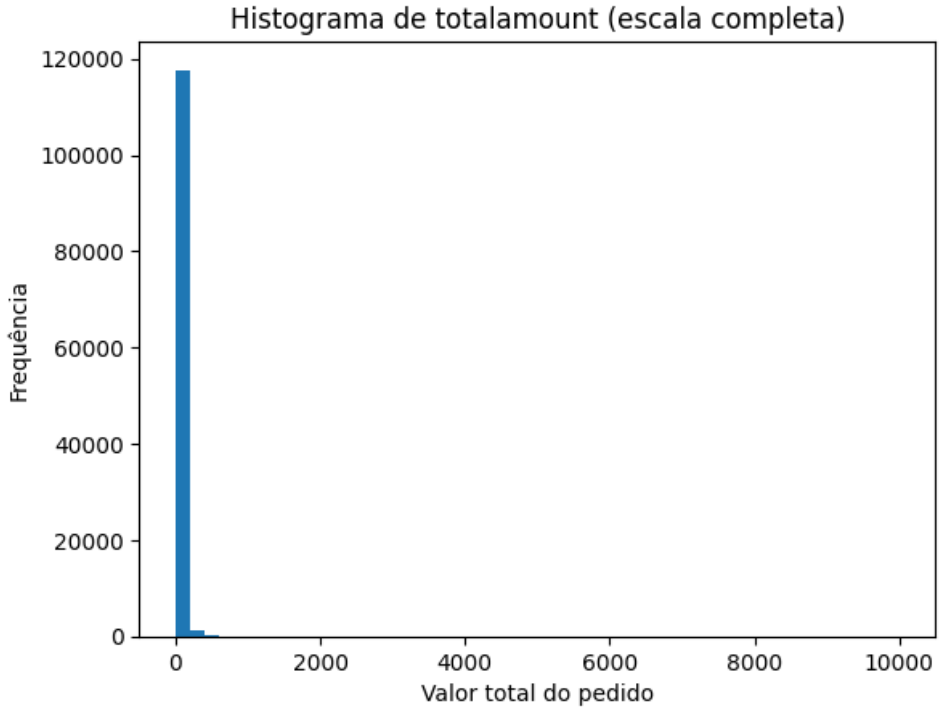

1.2.2 Histograma - Até o Percentil 99

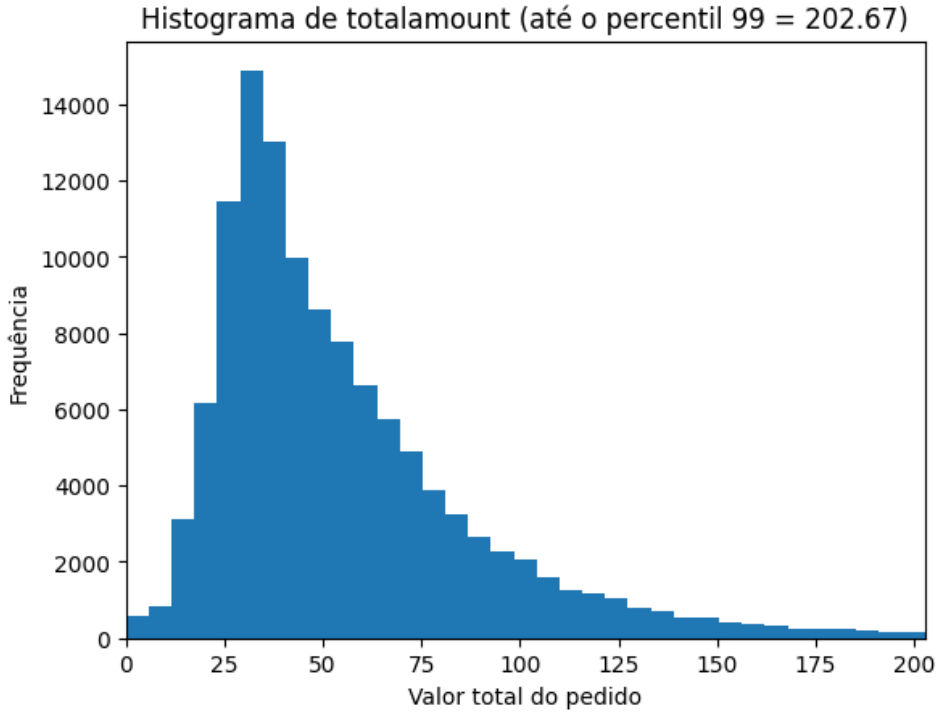

1.2.3 Boxplot - Escala Completa

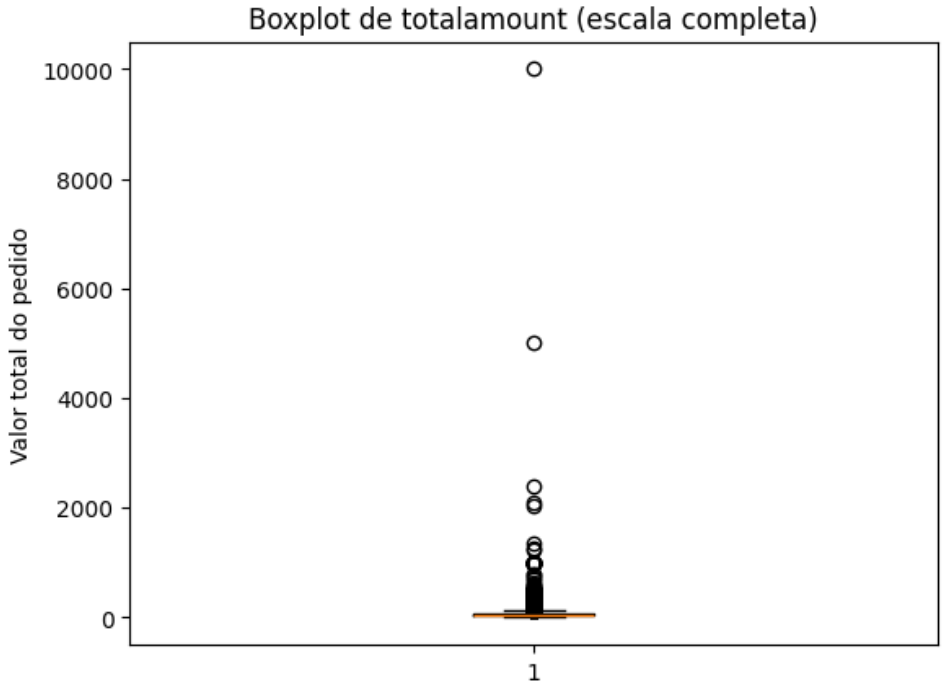

1.2.4 Boxplot - Até o Percentil 99

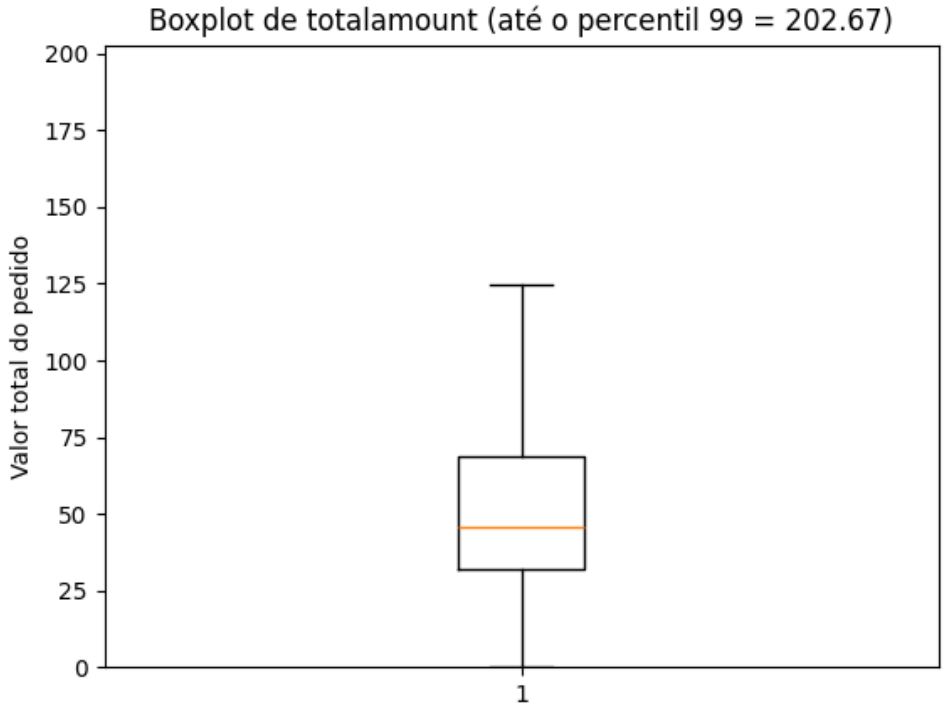

Observação: O percentil 99 da variável totalamount é aproximadamente 202.67, enquanto o valor máximo observado é 10000. Isso indica a presença de poucos

valores extremamente elevados (outliers), que afetam a escala dos gráficos quando toda a distribuição é considerada.

2. CUSTOMER

A seção CUSTOMER foi organizada com a mesma lógica de apresentação adotada em STOREORDER, reunindo inicialmente as distribuições descritivas das variáveis cadastrais e, em seguida, uma visualização gráfica complementar. O objetivo é caracterizar o perfil da base de clientes e, ao mesmo tempo, destacar limitações de completude e consistência que afetam interpretações inferenciais futuras.

2.1 Medidas descritivas e distribuição dos dados

Nesta subseção são apresentados os principais recortes descritivos da base CUSTOMER. Como o conjunto não possui a mesma riqueza de variáveis numéricas contínuas observada em STOREORDER, a análise foi estruturada a partir de distribuições de frequência e contagens relevantes para os campos gênero, idade e updated by.

2.1.1 Gênero

A base CUSTOMERS possui 160710 registros. Na variável gênero, observa-se forte concentração em valores não especificados ou ausentes, o que reduz a representatividade analítica do campo. A categoria "N" concentra 59,97% da base, enquanto 37,10% dos registros estão em branco (NULL). Entre os registros efetivamente preenchidos, há 1729 consumidores identificados como feminino (1,08%), 1439 como masculino (0,90%) e 1369 como "O" (0,85%), categoria interpretada como outro gênero não detalhado. Há ainda apenas 1 registro na categoria "I", tornando-a estatisticamente irrelevante para a análise.

Categoria	Quantidade	Percentual
N	96356	59,97%
NULL	59616	37,10%
F	1729	1,08%
M	1439	0,90%
O	1369	0,85%
I	1	0,00%

2.1.2 Idade

Como a base disponibilizava apenas a data de nascimento, foi necessária a conversão desse campo para idade. A análise identificou 8845 consumidores com idade acima de

18 anos, dos quais 3055 estão entre 20 e 50 anos e 5747 possuem mais de 50 anos. Contudo, os dados apresentam inconsistências importantes: aproximadamente 3292 registros indicam consumidores com 126 anos ou mais, o que sugere erro de preenchimento ou problema na origem do dado. Além disso, somente 8903 linhas da base possuem essa informação preenchida, reforçando uma limitação relevante de completude.

Faixa / condição	Quantidade
Idade > 18 anos	8845
Idade >= 20 e <= 50 anos	3055
Idade > 50 anos	5747
Idade >= 126 anos (discrepância)	3292
Registros com idade preenchida	8903

2.1.3 Campo updated by

O campo updated by foi utilizado como referência para identificar quais empresas, usuários ou sistemas mais alimentaram a base de clientes. Os dados mostram concentração expressiva em poucos responsáveis. Os maiores volumes aparecem em Cannoli API (23%), Admin (22%), HorusBI App (11%) e Cannoli Hangfire (9%), indicando que boa parte dos registros foi inserida por integrações sistêmicas ou perfis administrativos. Em seguida aparecem Agência Alca, Doceria Nobre e Paulo Bertelli, todos com participação de 4%, além de Planeta Conveniência e Maiara de Carvalho Silva, com 3% cada. A tabela a seguir consolida a distribuição apresentada no material de apoio.

Empresa / responsável	Quantidade	Percentual
Açai DuGoias - Loja 1	1	0%
Admin	34631	22%
Agência Alca	7050	4%
Agência Sower	325	0%
Agustina	1286	1%
Anderson Camargo	1493	1%
Anderson Lima	325	0%
Atelier Doce Amor	882	1%
Brand21 - Maiara	244	0%

Cannoli API	36900	23%
Cannoli Functions	793	0%
Cannoli Hangfire	14708	9%
CANNOLI MS	2	0%
cashback_engine	1	0%
Cleber Melo	533	0%
Consult Delivery	724	0%
Doceria Nobre	6863	4%
Emanoel - Mordidela Balsas	219	0%
Fernando Botti	1513	1%
Filipa	528	0%
Foxy Ads	2813	2%
Giralda - Atendente	40	0%
Henrique Augusto	1520	1%
HorusBI App	17513	11%
Igor Fontes	1	0%
Jorge Bertino	2516	2%
M.Arth Lanches	3934	2%
Maiara de Carvalho Silva	4316	3%
Mordidela	298	0%
Mordidela - Operacional	302	0%
O FORNÊS	201	0%
Oniads	17	0%
Paulo Bertelli	6472	4%
Planeta Conveniência	5206	3%

Polpa Norte - Presidente Prudente	1	0%
Polpanorte - Atacadão SBC	11	0%
Polpanorte - Balneário Shopping	71	0%
Polpanorte - Caceres	80	0%
Polpanorte - Campo Grande	79	0%
Polpanorte - Goiania	19	0%
Polpanorte - Horto	28	0%
Polpanorte - Londrina	73	0%
Polpanorte - Lucas	292	0%
Polpanorte - Maringá Park	57	0%
Polpanorte - Natalia	2	0%
Polpanorte - São José dos Pinhais	28	0%
Polpanorte - Shopping Praia de Belas	85	0%
Polpanorte - Willie Davids	50	0%
Raquel Viana	117	0%
Restaurante Cozinha Mineira	787	0%
ROBSON - CASA DA ESFIHA	187	0%
Sai Burguer	793	0%
Samara Franca	190	0%
split-phone	2445	2%
Support	941	1%

System	72	0%
Temaki Station	12	0%
Vitória Ferreira	120	0%

2.2 Visualizações gráficas

Foi gerada uma visualização complementar para o campo gênero, permitindo observar de forma sintética a concentração dos registros em categorias não especificadas e em valores ausentes. O gráfico reforça a limitação de completude já apontada na análise tabular.

2.2.1 Gráfico de pizza - gênero

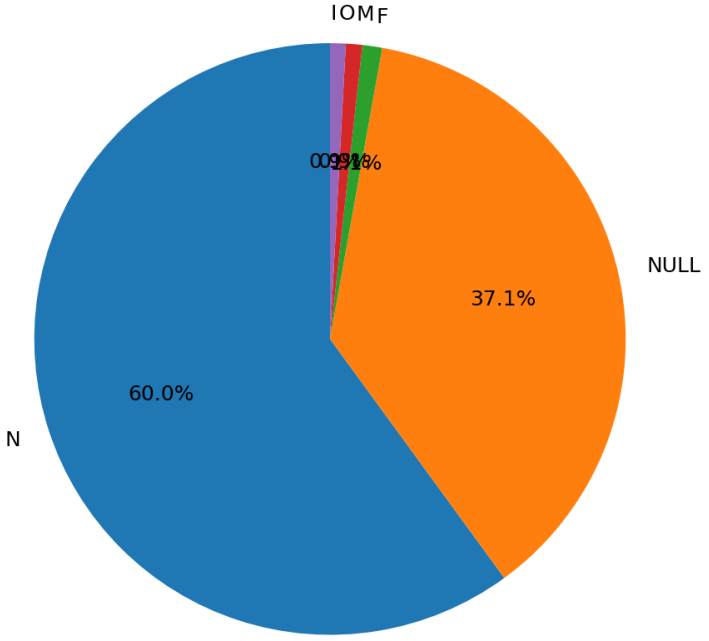

Figura - Distribuição do campo gênero na base CUSTOMERS.

2.3 Síntese analítica

Em conjunto, os dados de CUSTOMERS mostram que a base possui potencial para apoiar análises de perfil cadastral, mas ainda apresenta fragilidades importantes de qualidade. Os campos de gênero e idade possuem elevada ausência de preenchimento e, no caso da idade, registros claramente inconsistentes. Já o campo updated by revela forte centralização em poucos perfis e sistemas, o que pode ser útil para auditoria, rastreabilidade e revisão dos processos de alimentação da base. Portanto, antes de utilizar esses dados em análises inferenciais mais robustas, é recomendável aplicar etapas de saneamento, padronização e validação dos registros.